

GalStructNet-S3

Segmentación estructural probabilística de cubos IFU con incertidumbre anclada en física

Documento explicativo de la arquitectura para el comité — julio 2026

1. Motivación y planteamiento

GalStructNet-S3 segmenta cada espaxel de un cubo IFU (MaNGA y su gemelo simulado MaNGIA, derivado de TNG50) en cinco componentes estructurales — bulbo, disco, barra, brazo espiral y otro — y, de manera central, cuantifica cuánto puede afirmarse en cada espaxel. El modelo no predice una clase: predice una **distribución de Dirichlet** $\text{Dir}(\alpha)$ sobre el simplex de las cinco clases. La media α/S es la segmentación probabilística; la concentración $S = \sum \alpha$ es la confianza, y tiene unidades interpretables: pseudo-conteos comparables al número efectivo de partículas de la simulación que generó la etiqueta de ese espaxel.

Las etiquetas de entrenamiento provienen de la descomposición dinámica de galaxias TNG50 proyectadas como observaciones MaNGA. Cada etiqueta trae su propia estadística: el conteo efectivo de Kish $N_{\text{eff}} = (\sum w)^2 / \sum w^2$ de las partículas que contribuyeron al espaxel. Ese número es la pieza que permite anclar la incertidumbre del modelo a una referencia física medible.

2. Las tres contribuciones

(i) Supervisión Dirichlet anclada en N_{eff} . La pérdida principal es una divergencia KL entre Dirichlets: $\text{KL}(\text{Dir}(\alpha^*) \parallel \text{Dir}(\alpha))$ con ancla $\alpha^* = \kappa \cdot N_{\text{eff}} \cdot Y + 1$. A diferencia del evidencial deep learning clásico — criticado en la literatura 2022–2024 precisamente porque su incertidumbre carece de distribución de referencia — aquí la concentración de salida se supervisa contra una referencia frecuentista: el modelo aprende a afirmar tanta estadística como partículas independientes respaldan la etiqueta, ni más ni menos. El factor $\kappa \leq 1$ descuenta el error sistemático del pipeline de etiquetas y se somete a ablación.

(ii) Fusión multimodal modulada por precisión instrumental. Las tres modalidades (espectro, imagen, mapas físicos) se combinan por espaxel mediante atención sobre tres tokens, cuyos logits se sesgan con la precisión instrumental medida (IVAR del cubo, errores de pyPipe3D): donde el espectro es ruidoso, el modelo aprende a apoyarse en la morfología, y el mapa de pesos de atención resultante es en sí un producto científico — «en qué se apoyó el modelo en cada región». El gating se inicializa neutro y se gana su efecto por gradiente.

(iii) Predicción conformal sobre el simplex. Sobre las probabilidades calibradas se construyen conjuntos de predicción por espaxel con cobertura garantizada (split-conformal Mondrian, estratificado por clase y por N_{eff}). En el dominio real MaNGA la garantía formal se pierde por el cambio de distribución; el sistema lo declara y reporta cobertura empírica contra las máscaras ciudadanas de Galaxy Zoo 3D — sin sobre-afirmar.

Las tres se apoyan en un principio arquitectónico común, la **Red de Propagación de Evidencia (EPN)**: todo tensor del modelo es un par (señal, certeza), con dos garantías duras — certeza cero implica que el valor se ignora exactamente (los píxeles inválidos, NaN o fuera del campo de visión no contaminan a sus vecinos en ninguna capa, incluidas las interpolaciones), y la certeza decrece monótonamente con el error instrumental. La entrada, la salida y la etiqueta comparten unidad: pseudo-conteos.

3. Arquitectura




Figura 1 — Flujo de datos. Cada flecha transporta pares (señal, certeza); $H \times W$ es el tamaño nativo del bundle (19–127 fibras), nunca fijado en el código.

Encoder espectral (Mamba). Cada espaxel es una secuencia de ~ 6.600 canales espectrales. Un modelo de espacio de estados selectivo (Mamba) bidireccional la procesa con costo lineal en L y campo receptivo global: la relación entre líneas distantes (Ca II a $3933 \text{ \AA}$ frente a H α a $6563 \text{ \AA}$) se captura sin el costo cuadrático de la atención. La elección se defiende empíricamente: la ablación contra una CNN dilatada equivalente es obligatoria en el plan experimental.

Encoder espacial (Swin-T + FPN). Procesa la imagen g,r,i y es la única fuente de contexto morfológico de largo alcance («este espaxel está en la periferia del disco»). Una pirámide de rasgos recupera resolución espacial fina y alimenta el decoder con conexiones skip multi-escala.

Encoder físico (NormConv). Ocho mapas 2D — cinemática y poblaciones estelares de pyPipe3D más los momentos $h3/h4$ de pPXF, cuya correlación con V es la firma cinemática directa de las barras — se procesan con convoluciones normalizadas por certeza: la agregación espacial es un promedio convexo ponderado por c , de modo que un mapa dañado localmente no se interpola implícitamente hacia sus vecinos.

Cabezas duales y techo de evidencia. Dos cabezas comparten el tronco: una para la etiqueta ponderada por masa y otra por luz — los dos targets difieren sistemáticamente (la luz sobre-pesa brazos jóvenes; la masa, el bulbo viejo) y forzarlos sobre un mismo α inflaría la incertidumbre artificialmente. La cabeza de evidencia impone además el sesgo inductivo central: la evidencia emitida es $e = e_{\text{red}} \cdot h(c)$, donde h crece con la certeza propagada. El modelo puede emitir menos evidencia que ese techo (regiones nunca vistas), pero jamás más evidencia que la que respalda la calidad instrumental de la entrada: ignorancia instrumental implica ignorancia del modelo, por construcción y no por regularización. La divergencia entre ambas cabezas (mapa JS masa/luz) se exporta como producto científico.

Módulo PSF. La comparación con la etiqueta observada se hace convolucionando la *evidencia* ($\alpha - 1$) con el kernel PSF de cada cubo: la PSF redistribuye pseudo-conteos (conservándolos) en lugar de difuminar probabilidades, manteniendo la coherencia de unidades del sistema

completo.

4. Incertidumbre: qué se reporta y cómo se valida

Por espaxel y por target se emite la descomposición correcta por información mutua: incertidumbre **total** (TU), **aleatoria** (AU) — la ambigüedad física irreducible, alta en las fronteras reales bulbo/disco o barra/disco — y **epistémica** (EU = TU – AU) — lo que el modelo no sabe, alta fuera del dominio de entrenamiento. La separación se valida con dos pruebas: AU debe concentrarse en fronteras y EU en espaxels fuera de distribución (figura AU-EU), y EU debe predecir los errores del clasificador mejor que la vacuüty clásica (AUROC de detección de error). En la aplicación a MaNGA, EU funciona como detector del salto simulación→realidad y como criterio de triaje/abstención.

La métrica firma de la primera contribución es $\rho(S, \kappa \cdot N_{\text{eff}})$: la correlación de rango entre la concentración predicha y la estadística de partículas de la etiqueta, monitoreada en cada validación. Es el enunciado empírico que responde la crítica al EDL: existe distribución de referencia y la concentración la sigue.

5. Entrenamiento: currículo de cuatro etapas

Etapas	Datos	Objetivo
1 — SSL	MaNGIA u MaNGA, sin etiquetas	Reconstrucción espectral enmascarada (estilo MAE, por posición): el encoder espectral aprende representaciones compartidas entre simulación y observación desde el inicio.
2 — Superv.	MaNGIA con control de calidad	Segmentación dual + restricción física global. Criterios: IoU mediano > 0.5, $\rho(S, N_{\text{eff}}) > 0.4$, ECE < 0.15.
3 — Semi-sup.	MaNGIA + MaNGA (GZ3D débil + sin etiqueta)	Se añaden el término PSF, el regularizador de fronteras, la consistencia bajo simetrías y la supervisión débil de barras/brazos con Galaxy Zoo 3D (partición débil/validación disjunta, verificada por assert en entrenamiento y evaluación).
4 — Adapt. dominio	MaNGIA 50% + MaNGA 50%	Alineación de embeddings por MMD. Control: las métricas en simulación no caen y la incertidumbre epistémica sube en MaNGA donde el salto de dominio importa.

6. La escalera de ablación: las innovaciones se ganan su lugar

Ninguna primitiva EPN se asume: cada una entra al modelo final solo si su nivel de la escalera lo justifica, con las mismas semillas, particiones y presupuesto de cómputo, reproducible con un comando.

Nivel	Configuración	Pregunta que responde
A0	Baseline estándar (convoluciones, atención global, EDL anclada)	punto de referencia
A1	+ NormConv en tronco físico y decoder	¿la certeza en el tronco paga?
A2	concat / atención global / fusión por precisión	¿el gating por precisión paga?
A3	+ cabeza de evidencia con techo de certeza	¿el sesgo $S \leq f(c)$ mejora calibración y detección de error?
A4	PSF en evidencia vs. en probabilidad	¿la α -convolución mejora la nitidez intrínseca?

Criterio de adopción: A3 debe superar a A0 en verosimilitud suave **y** en AUROC de detección de error; empatar en IoU es aceptable — la familia compra incertidumbre fiable, no

necesariamente accuracy. Dos experimentos firma completan la defensa, imposibles para una red estándar sin reentrenar: degradar el test con ruido consistente con la IVAR escalada $\times \{1,2,4,8\}$ *actualizando la certeza* (la EPN debe degradar con gracia), y apagar 10–40% de espaxels vía $c = 0$ frente al baseline con imputación.

7. Estado de la implementación y pesos

La codificación de los siete hitos del plan está completa y validada por 147 pruebas automáticas contra una fixture sintética que codifica el contrato de datos ejecutable (incluidos los invariantes de cada primitiva EPN, la cobertura conformal y las pruebas de sobreajuste controlado en las que $p(S, \kappa \cdot N_{\text{eff}})$ se vuelve positiva). No existen aún pesos entrenados: el entrenamiento espera la generación de los datos definitivos (etiquetas TNG50 con N_{eff} por ambas ponderaciones y variante PSF). El único peso preentrenado externo previsto es la inicialización opcional ImageNet del encoder espacial; todo lo demás se entrena desde cero mediante el currículo. Caso piloto de validación rápida: TNG50-87-141934-0-127.

Documento generado desde las especificaciones v3 del repositorio galstructnet_s3 (las especificaciones prevalecen ante cualquier discrepancia). Detalle técnico por módulo: docs/ARQUITECTURA.md.